

Predicción del abandono universitario mediante Machine Learning

Lucas Beneyto

Pablo Candela

Alexander Herasimovich

25 de mayo de 2026

Asignatura: Aprendizaje Avanzado

Grado: Ingeniería en Inteligencia Artificial

Repositorio del proyecto:

github.com/lucasbeneyto/Proyecto_final_aprendizaje_avanzado

Resumen

Este trabajo aborda la predicción del abandono universitario mediante técnicas de aprendizaje automático. El problema se plantea como una tarea de clasificación binaria, donde la clase positiva corresponde a estudiantes que abandonan sus estudios. Para ello, se utiliza un dataset con información académica, administrativa, económica y personal de 4424 estudiantes. Tras preparar los datos y evitar posibles fugas de información, se entrenan y comparan distintos modelos de clasificación. El modelo final seleccionado es Gradient Boosting, que obtiene un rendimiento alto y equilibrado. Además del rendimiento predictivo, se analiza la explicabilidad del modelo mediante SHAP y se estudia su comportamiento entre distintos grupos de estudiantes mediante métricas de fairness. Finalmente, se aplica una estrategia de mitigación basada en umbrales por grupo para reducir algunas diferencias en falsos negativos.

Índice

1. Introducción	6
2. Descripción del problema	6
3. Descripción del dataset	7
4. Metodología	8
4.1. Preprocesamiento	8
4.2. Métricas de evaluación	9
5. Análisis exploratorio de datos	9
5.1. Distribución de la variable objetivo	9
5.2. Variables relevantes	10
6. Modelo baseline	10
6.1. Descripción del modelo	10
6.2. Resultados del baseline	11
6.3. Interpretación de errores	11
7. Comparación de modelos	12
7.1. Modelos evaluados	12
7.2. Ajuste de hiperparámetros	13
7.3. Resultados comparativos	13
7.4. Selección del modelo final	14
8. Resultados del modelo final	14
8.1. Métricas principales	14
8.2. Matriz de confusión	15
8.3. Curvas de evaluación	16
8.4. Discusión de resultados	17
9. Explicabilidad con SHAP	17
9.1. Importancia global de variables	17
9.2. Distribución de efectos SHAP	18
9.3. Explicaciones locales	19
10. Análisis de fairness	21
11. Mitigación	23
12. Conclusiones y trabajo futuro	25

Índice de figuras

1.	Distribución de la variable objetivo	10
2.	Matriz de confusión del modelo baseline	12
3.	Matriz de confusión del modelo final	15
4.	Curva ROC del modelo final	16
5.	Curva Precision-Recall del modelo final	16
6.	Importancia global de variables agrupadas según SHAP	18
7.	Distribución de efectos SHAP sobre la predicción de abandono	19
8.	Explicación local SHAP para un estudiante con alto riesgo de abandono . .	20
9.	Explicación local SHAP para un caso dudoso	21
10.	Recall del modelo por grupo	22
11.	Tasa de falsos negativos por grupo	23
12.	Tasa de falsos negativos antes y después de la mitigación según beca	24
13.	Tasa de falsos negativos antes y después de la mitigación según tasas aca- démicas al día	24

Índice de cuadros

1.	Resumen general del dataset	8
2.	Variables eliminadas por posible fuga de información	9
3.	Resultados del modelo baseline	11
4.	Comparación de modelos en test	13
5.	Comparación de modelos mediante validación cruzada	14
6.	Resultados del modelo final	15
7.	Resumen de métricas de fairness por grupo	22
8.	Umbrales utilizados en la mitigación por grupo	23
9.	Comparación de métricas antes y después de la mitigación	25

1. Introducción

El abandono universitario es un problema relevante tanto para los estudiantes como para las instituciones educativas. Desde el punto de vista del estudiante, abandonar una titulación puede implicar consecuencias académicas, económicas y personales. Desde el punto de vista de la universidad, supone una pérdida de recursos y evidencia la necesidad de detectar de forma temprana aquellos casos en los que puede ser conveniente ofrecer apoyo adicional.

En este trabajo se aborda el problema de la predicción del abandono académico mediante técnicas de aprendizaje automático. El objetivo principal es construir un modelo capaz de estimar si un estudiante presenta riesgo de abandonar sus estudios a partir de información académica, administrativa, económica y personal disponible en el dataset. Sin embargo, el trabajo no se centra únicamente en obtener un buen rendimiento predictivo, sino también en analizar aspectos importantes cuando un modelo de aprendizaje automático se aplica en un contexto real.

En concreto, se estudian dos problemáticas especialmente relevantes. En primer lugar, la interpretabilidad del modelo, ya que en un contexto educativo no basta con obtener una predicción, sino que también es importante comprender qué variables influyen en ella. En segundo lugar, se analiza la posible existencia de sesgos entre distintos grupos de estudiantes, ya que algunas variables del dataset pueden estar relacionadas con factores sociales o económicos.

Por tanto, la finalidad del sistema no es sustituir la decisión humana ni etiquetar automáticamente a los estudiantes, sino servir como una herramienta de apoyo. Un modelo de este tipo podría ayudar a priorizar intervenciones tempranas, como tutorías, seguimiento académico o medidas de acompañamiento, siempre bajo supervisión humana y con una interpretación cuidadosa de los resultados.

2. Descripción del problema

El problema se plantea como una tarea de clasificación supervisada. A partir de un conjunto de variables asociadas a cada estudiante, el modelo debe predecir si dicho estudiante pertenece o no al grupo de abandono académico. Por tanto, la variable objetivo representa si el estudiante abandona sus estudios o si, por el contrario, continúa matriculado o consigue graduarse.

Este problema tiene una motivación real clara. En un entorno universitario, detectar el abandono cuando ya se ha producido limita mucho la capacidad de actuación. En cambio, si se identifican patrones de riesgo de forma temprana, la institución podría activar mecanismos de apoyo antes de que la situación sea irreversible.

No obstante, se trata de un problema delicado porque las predicciones afectan directa-

mente a personas. Por este motivo, es importante analizar no solo el porcentaje de aciertos del modelo, sino también el tipo de errores que comete. Un falso positivo se produciría cuando el modelo clasifica como estudiante en riesgo a una persona que realmente no abandonará. Por otro lado, un falso negativo se produciría cuando el modelo predice que un estudiante no abandonará, pero finalmente sí lo hace. Este segundo caso es especialmente importante, ya que implica que el sistema no detecta a un estudiante que podría haber necesitado ayuda.

Por ello, además de métricas generales como la exactitud, se presta especial atención al *recall*, que mide la proporción de abandonos reales que el modelo consigue detectar, y al *F1-score*, que resume el equilibrio entre precisión y recall.

3. Descripción del dataset

El dataset utilizado contiene información de 4424 estudiantes y 35 variables. Estas variables recogen información de distinta naturaleza, incluyendo características académicas, administrativas, económicas y personales. Entre las variables académicas se incluyen datos relacionados con asignaturas matriculadas, evaluadas, aprobadas y calificaciones obtenidas. También aparecen variables administrativas y económicas, como el estado de pago de tasas, la existencia de deuda o la posesión de beca.

La variable objetivo original del dataset contiene tres clases:

- *Graduate*: estudiantes que se han graduado.
- *Enrolled*: estudiantes que continúan matriculados.
- *Dropout*: estudiantes que han abandonado.

Para adaptar el problema al objetivo del trabajo, se transformó la variable objetivo en una clasificación binaria. Las clases *Graduate* y *Enrolled* se agruparon en una única clase denominada *No Dropout*, ya que en ambos casos no se considera que el estudiante haya abandonado. La clase *Dropout* se mantuvo como la clase positiva del problema, al ser el evento que se desea detectar.

Cuadro 1: Resumen general del dataset

Elemento	Valor
Número de estudiantes	4424
Número de variables originales	35
Variable objetivo original	Target
Clases originales	<i>Graduate, Enrolled, Dropout</i>
Variable objetivo transformada	Target_bin
Clase positiva	<i>Dropout</i>

El enfoque binario permite centrar el análisis en la identificación temprana de estudiantes que podrían necesitar apoyo.

4. Metodología

La metodología seguida en el trabajo se diseñó con el objetivo de construir un flujo reproducible y coherente con el problema planteado. El proceso incluyó la preparación de los datos, el entrenamiento de distintos modelos, la evaluación de su rendimiento, la selección de un modelo final y el análisis posterior de interpretabilidad y fairness.

En primer lugar, se cargó el dataset y se transformó la variable objetivo original a una variable binaria. A continuación, se separaron las variables predictoras de la variable objetivo. Posteriormente, los datos se dividieron en un conjunto de entrenamiento y un conjunto de test. El conjunto de entrenamiento se utilizó para ajustar los modelos, mientras que el conjunto de test se reservó para evaluar el rendimiento final sobre datos no vistos.

4.1. Preprocesamiento

El preprocesamiento fue una parte fundamental del trabajo. Las variables numéricas se escalaron para que estuvieran en una escala comparable, lo cual es importante para modelos como la regresión logística o SVM. Las variables categóricas se transformaron mediante *One-Hot Encoding*, ya que muchos algoritmos no pueden trabajar directamente con categorías.

También se tuvo en cuenta el riesgo de *data leakage*. Este problema ocurre cuando el modelo utiliza información que no estaría disponible en el momento real de realizar la predicción. Como el objetivo es simular una detección temprana del abandono, se eliminaron variables futuras, especialmente aquellas relacionadas con el segundo semestre.

Cuadro 2: Variables eliminadas por posible fuga de información

Variable eliminada	Justificación
Curricular units 2nd sem (credited)	Información futura del segundo semestre
Curricular units 2nd sem (enrolled)	Información futura del segundo semestre
Curricular units 2nd sem (evaluations)	Información futura del segundo semestre
Curricular units 2nd sem (approved)	Información futura del segundo semestre
Curricular units 2nd sem (grade)	Información futura del segundo semestre
Curricular units 2nd sem (without evaluations)	Información futura del segundo semestre

El pipeline de preprocesamiento quedó compuesto por la transformación de la variable objetivo, la separación entre variables predictoras y variable objetivo, la división entrenamiento-test, el escalado de variables numéricas, la codificación *One-Hot* de variables categóricas y la eliminación de variables futuras.

4.2. Métricas de evaluación

Para evaluar los modelos se utilizaron distintas métricas de clasificación. La *accuracy* mide el porcentaje total de aciertos, pero por sí sola no es suficiente en este problema. Por ello, también se utilizaron precision, recall, F1-score y ROC-AUC.

La precision mide, de todos los estudiantes que el modelo predice como abandono, cuántos realmente abandonan. El recall mide, de todos los abandonos reales, cuántos consigue detectar el modelo. El F1-score combina precision y recall en una única métrica. Finalmente, el ROC-AUC mide la capacidad general del modelo para separar correctamente las clases *Dropout* y *No Dropout*.

5. Análisis exploratorio de datos

El análisis exploratorio permitió conocer la distribución de la variable objetivo y estudiar la relación inicial entre el abandono y distintas variables académicas, administrativas y personales.

5.1. Distribución de la variable objetivo

La variable objetivo original presenta tres clases: *Graduate*, *Enrolled* y *Dropout*. Tras la transformación binaria, los estudiantes graduados y matriculados se agrupan como *No Dropout*, mientras que los estudiantes que abandonan se mantienen como clase positiva.



distribucion_target.png

Figura 1: Distribución de la variable objetivo

El análisis muestra que existe cierto desbalance entre clases, ya que la clase *No Dropout* es mayoritaria. Por este motivo, además de accuracy, se utilizan métricas como recall, precision y F1-score.

5.2. Variables relevantes

El EDA mostró que el abandono está relacionado con variables académicas, económicas y administrativas. En particular, las variables del primer semestre, como asignaturas aprobadas, asignaturas matriculadas y calificaciones, muestran una relación clara con el abandono. También aparecen patrones relevantes en variables como deuda, beca, tasas académicas al día, edad de matrícula o género.

Estos resultados justifican el uso de modelos de clasificación y también motivan el posterior análisis de explicabilidad y fairness.

6. Modelo baseline

6.1. Descripción del modelo

Como primer punto de referencia se entrenó una regresión logística. Este modelo se utilizó como baseline porque es sencillo, rápido de entrenar e interpretable, lo que permite

tener una primera referencia antes de probar modelos más complejos.

El entrenamiento se realizó mediante un pipeline que incluye imputación de valores perdidos, escalado de variables numéricas y codificación One-Hot para variables categóricas. De esta forma, el mismo preprocesado se aplica tanto en entrenamiento como en test, evitando fugas de información.

6.2. Resultados del baseline

La regresión logística obtuvo un rendimiento competitivo en el conjunto de test. Los resultados principales se muestran en la Tabla 3.

Cuadro 3: Resultados del modelo baseline

Métrica	Valor
Accuracy	0.856
Precision	0.849
Recall	0.673
F1-score	0.750
ROC-AUC	0.909

El valor de ROC-AUC muestra que el modelo separa bastante bien las clases. Sin embargo, el recall es menor que la precision, lo que indica que todavía hay estudiantes que realmente abandonan y que el modelo no detecta.

6.3. Interpretación de errores

En este problema, los falsos negativos son especialmente importantes. Un falso negativo corresponde a un estudiante que realmente abandona, pero que el modelo clasifica como *No Dropout*. Desde el punto de vista educativo, este error es relevante porque el estudiante podría no recibir una intervención temprana.




Figura 2: Matriz de confusión del modelo baseline

Además de la evaluación en test, se realizó validación cruzada con cinco particiones. El F1-score medio fue de 0.742, el recall medio de 0.674, la precision media de 0.827 y el ROC-AUC medio de 0.897. Estos valores confirman que el baseline ofrece un rendimiento estable, aunque mejorable en la detección de abandonos.

7. Comparación de modelos

7.1. Modelos evaluados

Tras establecer el baseline, se entrenaron y compararon varios modelos de clasificación:

- Regresión logística.
- Árbol de decisión.
- Random Forest.
- Support Vector Machine.
- Gradient Boosting.

El objetivo de esta comparación fue comprobar si modelos más flexibles eran capaces de mejorar la detección de estudiantes en riesgo de abandono.

7.2. Ajuste de hiperparámetros

Para algunos modelos se realizó ajuste de hiperparámetros mediante `GridSearchCV`, usando validación cruzada con cinco particiones y optimizando el F1-score. Esta métrica se eligió porque combina precisión y recall, lo que resulta adecuado en un problema donde interesa detectar correctamente la clase *Dropout* sin aumentar excesivamente los falsos positivos.

Los mejores hiperparámetros encontrados fueron:

- **SVM:** `C = 10`, `kernel = linear`, `gamma = scale`.
- **Random Forest:** `n_estimators = 200`, `max_depth = 20`, `min_samples_split = 5`, `min_samples_leaf = 1`.
- **Gradient Boosting:** `n_estimators = 200`, `learning_rate = 0.1`, `max_depth = 3`.

7.3. Resultados comparativos

La Tabla 4 muestra los resultados obtenidos en el conjunto de test. La regresión logística obtiene el mejor F1-score en test, seguida de Gradient Boosting. Sin embargo, ambos modelos presentan resultados muy cercanos.

Cuadro 4: Comparación de modelos en test

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.871	0.863	0.711	0.780	0.912
Gradient Boosting	0.860	0.831	0.708	0.764	0.908
SVM	0.862	0.865	0.676	0.759	0.904
Random Forest	0.859	0.853	0.676	0.754	0.902
Decision Tree	0.783	0.660	0.669	0.664	0.753

También se compararon los modelos mediante validación cruzada. En este caso, Gradient Boosting obtuvo el mayor F1-score medio, aunque la diferencia con la regresión logística fue muy pequeña.

Cuadro 5: Comparación de modelos mediante validación cruzada

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Gradient Boosting	0.858	0.831	0.704	0.761	0.899
Logistic Regression	0.858	0.832	0.702	0.761	0.902
SVM	0.856	0.837	0.687	0.754	0.897
Random Forest	0.849	0.840	0.657	0.737	0.891
Decision Tree	0.778	0.652	0.664	0.658	0.748

Nota informativa

Durante la presentación se planteó por qué la regresión logística obtuvo mejores resultados que el árbol de decisión. Aunque un árbol de decisión puede capturar relaciones no lineales, un árbol individual suele ser más inestable y más propenso al sobreajuste. En este caso, la regresión logística obtuvo mejores resultados porque muchas variables tienen una relación bastante directa con el abandono, como las asignaturas aprobadas, las notas, la deuda o las tasas académicas. Por ello, una frontera lineal fue suficiente para separar bien las clases. En cambio, el árbol de decisión aprendió reglas más específicas del entrenamiento y generalizó peor.

7.4. Selección del modelo final

Aunque la regresión logística fue el modelo con mejor F1-score en test, se seleccionó Gradient Boosting como modelo final porque obtuvo el mejor F1-score medio en validación cruzada y mantuvo un rendimiento alto y equilibrado en todas las métricas.

Además, Gradient Boosting permite capturar relaciones no lineales entre variables, lo que puede ser útil en un problema donde el abandono depende de factores académicos, económicos y administrativos. También resulta adecuado para el análisis posterior de explicabilidad mediante SHAP.

8. Resultados del modelo final

8.1. Métricas principales

El modelo final seleccionado fue Gradient Boosting. Sus resultados en el conjunto de test se muestran en la Tabla 6.

Cuadro 6: Resultados del modelo final

Métrica	Valor
Accuracy	0.860
Precision	0.831
Recall	0.708
F1-score	0.764
ROC-AUC	0.908

Estos resultados indican que el modelo tiene una buena capacidad predictiva. El ROC-AUC de 0.908 muestra que el modelo distingue bien entre estudiantes que abandonan y estudiantes que no abandonan. Aun así, el recall de 0.708 indica que todavía existe un porcentaje de estudiantes que realmente abandonan y que no son detectados.

8.2. Matriz de confusión

La matriz de confusión del modelo final se muestra en la Figura 3. El modelo clasifica correctamente 560 estudiantes como *No Dropout* y 201 como *Dropout*. Sin embargo, comete 83 falsos negativos y 41 falsos positivos.




Figura 3: Matriz de confusión del modelo final

Los falsos negativos son el error más delicado en este contexto, ya que representan estudiantes que abandonan pero que el modelo no identifica como casos de riesgo.

8.3. Curvas de evaluación

Para analizar el comportamiento del modelo más allá de un único umbral de clasificación, se utilizan la curva ROC y la curva Precision-Recall.




Figura 4: Curva ROC del modelo final

La curva ROC confirma la buena capacidad del modelo para separar ambas clases. El área bajo la curva se sitúa alrededor de 0.908.




Figura 5: Curva Precision-Recall del modelo final

La curva Precision-Recall es especialmente útil porque la clase positiva es *Dropout*. Esta curva permite analizar el equilibrio entre detectar más estudiantes en riesgo y mantener

una precisión razonable.

8.4. Discusión de resultados

En conjunto, Gradient Boosting ofrece un rendimiento sólido y equilibrado. El modelo consigue una buena precisión, lo que significa que la mayoría de estudiantes clasificados como *Dropout* realmente abandonan. También obtiene un recall aceptable, aunque todavía deja sin detectar 83 casos reales de abandono.

Por tanto, el modelo puede ser útil como herramienta de apoyo para detectar estudiantes en riesgo, pero no debería utilizarse como sistema automático de decisión. Sus predicciones deben interpretarse como una señal de alerta que puede ayudar a priorizar intervenciones, no como una decisión definitiva.

9. Explicabilidad con SHAP

Tras seleccionar el modelo final, se utilizó SHAP para interpretar qué variables influyen más en la predicción de abandono. Este análisis permite comprobar si el modelo se apoya en patrones coherentes con el problema y no únicamente en métricas globales.

9.1. Importancia global de variables

La importancia global se calculó mediante la media del valor absoluto de los valores SHAP. Los resultados muestran que las variables con mayor peso están relacionadas principalmente con el rendimiento académico temprano, especialmente las asignaturas aprobadas y las calificaciones del primer semestre.

También aparecen variables administrativas y socioeconómicas, como el estado de pago de las tasas, la beca, la deuda, la edad de matrícula o el género. Esto indica que el modelo combina información académica con factores del contexto del estudiante.




Figura 6: Importancia global de variables agrupadas según SHAP

9.2. Distribución de efectos SHAP

El gráfico beeswarm permite analizar no solo qué variables son importantes, sino también si sus valores aumentan o reducen la probabilidad estimada de abandono. En general, el modelo asigna mayor riesgo a estudiantes con bajo rendimiento académico en el primer semestre.




Figura 7: Distribución de efectos SHAP sobre la predicción de abandono

Este resultado es coherente con el objetivo del proyecto, ya que el rendimiento académico inicial suele ser uno de los indicadores más claros del abandono. Aun así, la presencia de variables económicas y administrativas justifica realizar un análisis posterior de fairness.

9.3. Explicaciones locales

Además del análisis global, se interpretaron predicciones individuales mediante gráficos waterfall. Estos gráficos muestran qué variables empujan una predicción hacia *Dropout* y cuáles la reducen.




Figura 8: Explicación local SHAP para un estudiante con alto riesgo de abandono

En el caso de alto riesgo, la predicción se ve impulsada principalmente por variables relacionadas con bajo rendimiento académico y factores administrativos desfavorables.




Figura 9: Explicación local SHAP para un caso dudoso

El caso dudoso muestra una predicción menos clara, con variables que empujan en direcciones opuestas. Este tipo de ejemplo refuerza la idea de que el modelo debe utilizarse como apoyo y no como una decisión automática.

10. Análisis de fairness

Después de interpretar el modelo, se analizó si su rendimiento era similar entre distintos grupos de estudiantes. Este paso es importante porque un modelo puede tener buenas métricas globales y, aun así, cometer más errores en ciertos subgrupos.

Las variables sensibles analizadas fueron **Gender**, **Scholarship holder**, **Debtor**, **Tuition fees up to date** e **International**. Se prestó especial atención al recall y a la tasa de falsos negativos, ya que un falso negativo representa un estudiante que realmente abandona pero que el modelo no detecta como caso de riesgo.

Cuadro 7: Resumen de métricas de fairness por grupo

Variable	Grupo	N	Dropout real	Recall	FNR
Gender	0	564	0.245	0.696	0.304
Gender	1	321	0.455	0.719	0.281
Scholarship holder	0	654	0.390	0.729	0.271
Scholarship holder	1	231	0.126	0.517	0.483
Debtor	0	795	0.292	0.655	0.345
Debtor	1	90	0.578	0.942	0.058
Tuition fees up to date	0	114	0.860	0.990	0.010
Tuition fees up to date	1	771	0.241	0.559	0.441
International	0	859	0.321	0.699	0.301
International	1	26	0.308	1.000	0.000

Los resultados muestran diferencias moderadas por género, pero brechas más claras en variables económicas y administrativas. Destacan especialmente **Scholarship holder** y **Tuition fees up to date**. En esta última, el grupo con valor 1 presenta un recall de 0.559 y una tasa de falsos negativos de 0.441, frente a un recall de 0.990 y una FNR de 0.010 en el grupo con valor 0.




Figura 10: Recall del modelo por grupo




Figura 11: Tasa de falsos negativos por grupo

La tasa de falsos negativos es la métrica más relevante en este contexto. Si es elevada en un grupo, significa que el modelo deja sin detectar a más estudiantes que realmente abandonan. Por tanto, aunque el rendimiento general del modelo sea bueno, estas diferencias deben tenerse en cuenta antes de usarlo en un entorno real.

11. Mitigación

Para reducir algunas diferencias entre grupos se aplicó una mitigación basada en umbrales específicos. Esta estrategia no cambia el entrenamiento del modelo, sino la regla final de decisión: según el grupo, se modifica el umbral a partir del cual una probabilidad se clasifica como *Dropout*.

La mitigación se centró en **Scholarship holder** y **Tuition fees up to date**, ya que eran dos de las variables con diferencias más relevantes en recall y falsos negativos.

Cuadro 8: Umbrales utilizados en la mitigación por grupo

Grupo	Umbral elegido
Sin beca + tasas no al día	0.20
Sin beca + tasas al día	0.11
Con beca + tasas no al día	0.68
Con beca + tasas al día	0.12

El objetivo de estos umbrales es aumentar la sensibilidad del modelo en los grupos donde inicialmente se detectaban peor los estudiantes que abandonaban.




Figura 12: Tasa de falsos negativos antes y después de la mitigación según beca




Figura 13: Tasa de falsos negativos antes y después de la mitigación según tasas académicas al día

La mitigación reduce la tasa de falsos negativos en los grupos analizados. Por ejemplo, para `Scholarship holder = 0`, la FNR baja de 0.271 a 0.043, y para `Tuition fees up to date = 1`, baja de 0.441 a 0.108.

Cuadro 9: Comparación de métricas antes y después de la mitigación

Variable	Modelo	Grupo	Precision	Recall	FNR
Scholarship holder	Original	0	0.838	0.729	0.271
Scholarship holder	Mitigado	0	0.564	0.957	0.043
Scholarship holder	Original	1	0.750	0.517	0.483
Scholarship holder	Mitigado	1	0.370	0.690	0.310
Tuition fees up to date	Original	0	0.907	0.990	0.010
Tuition fees up to date	Mitigado	0	0.907	1.000	0.000
Tuition fees up to date	Original	1	0.770	0.559	0.441
Tuition fees up to date	Mitigado	1	0.438	0.892	0.108

El principal inconveniente es la pérdida de precisión en algunos grupos. Es decir, el modelo detecta más estudiantes en riesgo, pero también genera más falsos positivos. En este problema puede ser un compromiso razonable, ya que un falso positivo supondría ofrecer apoyo adicional, mientras que un falso negativo implica no detectar a un estudiante que realmente abandona.

12. Conclusiones y trabajo futuro

En este proyecto se ha desarrollado un modelo de Machine Learning para predecir el abandono universitario como un problema de clasificación binaria. La clase positiva se definió como *Dropout*, agrupando *Graduate* y *Enrolled* como *No Dropout*.

Durante la preparación de los datos se eliminaron variables que podían producir fuga de información, especialmente las relacionadas con el segundo semestre. Esto permitió simular un escenario de predicción temprana, usando información disponible al inicio del recorrido académico.

Tras comparar varios modelos, se seleccionó Gradient Boosting como modelo final. El modelo obtuvo un rendimiento alto, con una accuracy aproximada de 0.86, precision de 0.83, recall de 0.71, F1-score de 0.76 y ROC-AUC de 0.91. Estos resultados indican una buena capacidad predictiva, aunque todavía existen falsos negativos, es decir, estudiantes que realmente abandonan pero que el modelo no detecta.

El análisis con SHAP mostró que las variables más influyentes están relacionadas con el rendimiento académico temprano, especialmente las asignaturas aprobadas y las calificaciones del primer semestre. Esto confirma que el modelo aprende patrones coherentes con el problema. También aparecen variables administrativas y socioeconómicas, lo que hizo necesario estudiar posibles diferencias entre grupos.

El análisis de fairness mostró que el rendimiento no es completamente homogéneo. Las mayores diferencias aparecen en variables como **Scholarship holder**, **Debtor** y **Tuition**

`fees up to date`. En este contexto, la tasa de falsos negativos es especialmente importante, ya que dejar sin detectar a un estudiante en riesgo puede impedir que reciba apoyo.

La mitigación mediante umbrales específicos permitió reducir parte de estas diferencias, aumentando el recall y reduciendo falsos negativos en algunos grupos. Sin embargo, también redujo la precisión, por lo que existe un compromiso entre detectar más estudiantes en riesgo y aumentar los falsos positivos.

Como conclusión general, el modelo puede ser útil como herramienta de apoyo para priorizar intervenciones tempranas, tutorías o seguimiento académico. No debería utilizarse como sistema automático de decisión, sino como una ayuda complementaria supervisada por profesionales educativos.

Como trabajo futuro, sería recomendable validar el modelo con datos de otros cursos académicos, estudiar mejor la calibración de las probabilidades, incorporar nuevas variables sobre el contexto del estudiante y probar otras estrategias de mitigación de sesgos.

Referencias

- [1] Realinho, V., Vieira Martins, M., Machado, J., and Baptista, L. (2021). *Predict Students' Dropout and Academic Success*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5MC89>
- [2] Lundberg, S. M., and Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. Advances in Neural Information Processing Systems, 30.
- [3] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.